


Wstęp do uczenia maszynowego - projekt

Mateusz Brochocki

Przygotowanie danych

- Zlokalizowanie braków i zamiana ich wartości (-7, -8, -9) na NaN
- Zaaplikowanie funkcji $\log(1 + x)$ oraz $\log(\frac{1}{1+x} + 1)$ w celu zlikwidowania skośności rozkładów
- Uzupelnienie braków danych za pomocą *SimpleImputer* (*strategy="most_frequent"*) oraz *IterativeImputer*
- Wyskalowanie zmiennych za pomocą *StandardScaler*
- Selekcja zmiennych za pomocą *SelectFromModel* (*LogisticRegression (penalty="l2")*)
- Podzielenie zbioru na treningowy i testowy w stosunku 85:15



Poszukiwanie optymalnego modelu

Używamy trzykrotnej krosvalidacji w celu znalezienia optymalnego modelu z optymalnymi hiperparametrami:


- `DecisionTreeClassifier (max_depth=4, min_samples_leaf=40, min_samples_split=195)`
- `RandomForestClassifier (max_depth=4, min_samples_leaf=40, min_samples_split=195, n_estimators = 50 )`
- `ExtraTreesClassifier (max_depth=4, min_samples_leaf=40, min_samples_split=195, n_estimators=100 )`
- `LogisticRegression (C=0.25, penalty='l1', solver='saga')`
- `LogisticRegression (C=0.1, penalty='l2', solver='saga')`
- `SVC (C=0.5)`
- `LinearDiscriminantAnalysis()`
- `QuadraticDiscriminantAnalysis (reg_param=0.3)`
- `KNeighborsClassifier (n_neighbors=40, weights='distance')`
- `GradientBoostingClassifier (loss='exponential', n_estimators=500, learning_rate = 0.01)`

Ocena jakości modeli cz.1


Model	Balanced accuracy na treningowym	Balanced accuracy na testowym
Drzewo decyzyjne	0.7227	0.7079
Las losowy	0.7343	0.7145
ExtraTrees	0.7153	0.6923
Regresja logistyczna (regularyzacja l1)	0.7321	0.7181
Regresja logistyczna (regularyzacja l2)	0.7305	0.7164
Wektory podpierające	0.7383	0.7268
LDA	0.7275	0.7218
QDA	0.7129	0.7060
k-najbliższych sąsiadów	0.9793	0.7125
GradientBoosting	0.7531	0.7125

Ocena jakości modeli cz.2

Krzywa ROC dla zbioru testowego dla drzew i regresji



Krzywa ROC dla zbioru testowego (pozostałe modele)




Wnioski

Wszystkie modele osiągają zadowalającą predykcję dla zbioru testowego. Najlepszym z nich okazał się model SVC ($C=0.5$). Może warto wykorzystać go w metodzie baggingu i w połączeniu z innymi metodami w votingu i stackingu?




Ostateczny model

Miara balanced accuracy w zależności od liczby modeli użytych do tworzenia modelu metodą voting



Najlepiej sprawdza się voting ze wszystkimi modelami.

Miara balanced accuracy w zależności od liczby modeli użytych do tworzenia modelu metodą stacking



Najlepiej sprawdza się stacking z sześcioma najlepszymi modelami.

Ostateczny wynik (BA)

0.733855

Dziękuję za uwagę

